KẾ HOẠCH & PHÂN CHIA NHIỆM VỤ BÀI TẬP LỚN MÔN HỌC MÁY

ĐỀ TÀI: PHÂN TÍCH CẢM XÚC ĐÁNH GIÁ TIẾNG VIỆT THEO HƯỚNG CROSS-DOMAIN

---

1. TỔNG QUAN ĐỀ TÀI

1.1. Bối cảnh

Phân tích cảm xúc (Sentiment Analysis) là một bài toán quan trọng trong lĩnh vực Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), nhằm xác định thái độ hoặc cảm xúc được thể hiện trong một đoạn văn bản.

Trong thực tế, dữ liệu đánh giá của người dùng có sự khác biệt lớn giữa các lĩnh vực. Ví dụ, đánh giá sản phẩm trên các nền tảng thương mại điện tử thường chứa các từ ngữ liên quan đến sản phẩm, giá cả, giao hàng và đóng gói, trong khi đánh giá khách sạn hoặc nhà hàng lại tập trung vào dịch vụ, nhân viên, món ăn, phòng ở, vị trí và không gian.

Do đó, một mô hình được huấn luyện trên một miền dữ liệu có thể hoạt động tốt trên chính miền đó nhưng suy giảm hiệu năng khi áp dụng sang một miền khác. Hiện tượng này được gọi là Domain Shift.

Đề tài tập trung xây dựng và đánh giá hệ thống phân loại cảm xúc tiếng Việt trong hai miền dữ liệu khác nhau, từ đó nghiên cứu khả năng tổng quát hóa của các mô hình học máy khi chuyển đổi giữa các miền.

---

2. MỤC TIÊU ĐỀ TÀI

2.1. Mục tiêu tổng quát

Xây dựng hệ thống phân loại cảm xúc cho các đánh giá tiếng Việt thành ba lớp:

- Negative - Tiêu cực
- Neutral - Trung tính
- Positive - Tích cực

Đồng thời so sánh khả năng hoạt động của các mô hình học máy truyền thống và mô hình Transformer trong cùng miền dữ liệu và khác miền dữ liệu.

2.2. Mục tiêu cụ thể

Đề tài hướng tới các mục tiêu:

1. Thu thập và chuẩn hóa hai bộ dữ liệu đánh giá tiếng Việt thuộc hai miền khác nhau:
    - Miền A: Đánh giá sản phẩm/thương mại điện tử.
    - Miền B: Đánh giá khách sạn/nhà hàng.
2. Xây dựng quy trình tiền xử lý dữ liệu văn bản tiếng Việt.
3. Phân tích đặc điểm và sự khác biệt giữa hai miền dữ liệu thông qua EDA.
4. Xây dựng mô hình Baseline sử dụng TF-IDF kết hợp với:
    - Logistic Regression.
    - LinearSVC.
5. Đánh giá mô hình trong hai trường hợp:
    - In-domain.
    - Cross-domain.
6. Xây dựng mô hình nâng cao sử dụng PhoBERT để so sánh với các mô hình Machine Learning truyền thống.
7. Khảo sát Focal Loss trong trường hợp dữ liệu có sự mất cân bằng giữa các lớp.
8. Phân tích các trường hợp mô hình dự đoán sai và xác định nguyên nhân của lỗi.
9. Đưa ra nhận xét về ảnh hưởng của Domain Shift đối với bài toán phân loại cảm xúc tiếng Việt.

---

3. CÂU HỎI NGHIÊN CỨU

Đề tài tập trung trả lời các câu hỏi sau:

RQ1.

Các mô hình Machine Learning truyền thống sử dụng TF-IDF có thể phân loại cảm xúc tiếng Việt hiệu quả đến mức nào?

RQ2.

PhoBERT có cải thiện hiệu năng so với các mô hình Machine Learning truyền thống hay không?

RQ3.

Hiệu năng của mô hình thay đổi như thế nào khi chuyển từ miền dữ liệu huấn luyện sang một miền dữ liệu khác?

RQ4.

Những nguyên nhân chính dẫn đến lỗi dự đoán trong bài toán Cross-domain Sentiment Analysis là gì?

---

4. DỮ LIỆU

4.1. Yêu cầu lựa chọn dữ liệu

Đề tài sử dụng hai bộ dữ liệu thuộc hai miền khác nhau.

Domain A - E-commerce/Product Reviews

Dữ liệu đánh giá sản phẩm hoặc thương mại điện tử.

Các nội dung có thể xuất hiện:

- Chất lượng sản phẩm.
- Giá cả.
- Giao hàng.
- Đóng gói.
- Người bán.
- Trải nghiệm mua hàng.

Domain B - Hotel/Restaurant Reviews

Dữ liệu đánh giá khách sạn hoặc nhà hàng.

Các nội dung có thể xuất hiện:

- Chất lượng dịch vụ.
- Nhân viên.
- Món ăn.
- Phòng.
- Vị trí.
- Không gian.
- Giá cả.
- Vệ sinh.

Hai bộ dữ liệu cần đáp ứng các yêu cầu:

- Chủ yếu sử dụng tiếng Việt.
- Có nội dung review dạng văn bản.
- Có thể chuẩn hóa về ba lớp sentiment.
- Có nguồn dữ liệu rõ ràng.
- Có quy mô đủ lớn để thực hiện các thí nghiệm.
- Có thể sử dụng hợp pháp cho mục đích học tập/nghiên cứu.

Tên và nguồn chính thức của hai dataset sẽ được bổ sung sau khi nhóm hoàn tất bước khảo sát và kiểm tra dữ liệu.

---

5. CHUẨN HÓA NHÃN

Toàn bộ dữ liệu được đưa về cùng hệ thống nhãn:

Nhãn	Ý nghĩa
0	Negative
1	Neutral
2	Positive

Trong trường hợp dataset có rating từ 1 đến 5 sao, có thể sử dụng quy tắc:

- 1-2 sao → Negative.
- 3 sao → Neutral.
- 4-5 sao → Positive.

Quy tắc chuyển đổi chỉ được áp dụng sau khi kiểm tra ý nghĩa của rating trong dataset.

Nếu dataset đã cung cấp sentiment label thì ưu tiên sử dụng nhãn gốc sau khi kiểm tra và chuẩn hóa.

---

6. TIỀN XỬ LÝ DỮ LIỆU

Xây dựng một pipeline tiền xử lý thống nhất cho cả hai miền.

6.1. Các bước

1. Loại bỏ dữ liệu thiếu.
2. Loại bỏ dữ liệu trùng lặp.
3. Chuẩn hóa Unicode.
4. Chuẩn hóa khoảng trắng.
5. Xử lý URL.
6. Xử lý ký tự đặc biệt không cần thiết.
7. Xử lý các biểu tượng hoặc emoji tùy theo thí nghiệm.
8. Chuẩn hóa một số từ viết tắt và teencode phổ biến.
9. Tách từ tiếng Việt đối với các mô hình cần word-level representation.
10. Chuẩn hóa sentiment label.
11. Kiểm tra lại dữ liệu sau preprocessing.

6.2. Lưu ý đối với dataset lớn

Nếu dataset có quy mô rất lớn, nhóm không nhất thiết sử dụng toàn bộ dữ liệu cho tất cả thí nghiệm.

Có thể sử dụng phương pháp Stratified Sampling để tạo tập dữ liệu đại diện, đảm bảo tỷ lệ các lớp sentiment được duy trì.

Nhóm phải ghi rõ:

- Quy mô dataset ban đầu.
- Quy mô dataset sau sampling.
- Tỷ lệ các lớp.
- Random seed.
- Phương pháp lấy mẫu.

---

7. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU - EDA

EDA được thực hiện độc lập trên hai miền.

7.1. Phân bố sentiment

Thống kê số lượng và tỷ lệ:

- Negative.
- Neutral.
- Positive.

Mục đích là xác định mức độ cân bằng/mất cân bằng giữa các lớp.

7.2. Phân tích độ dài văn bản

Thống kê:

- Số ký tự.
- Số từ.
- Độ dài trung bình.
- Độ dài ngắn nhất/lớn nhất.

7.3. Phân tích từ vựng

Thống kê:

- Unigram phổ biến.

- Bigram phổ biến.
- Các từ khóa đặc trưng của từng miền.

7.4. So sánh hai miền

Phân tích sự khác biệt về vocabulary giữa Domain A và Domain B.

Ví dụ:

Domain A có thể chứa các từ liên quan đến:

- sản phẩm;
- giao hàng;
- đóng gói;
- shop;
- giá.

Domain B có thể chứa các từ liên quan đến:

- phục vụ;
- nhân viên;
- món ăn;
- phòng;
- không gian.

Kết quả EDA được sử dụng để giải thích hiện tượng Domain Shift trong phần phân tích kết quả.

---

8. MÔ HÌNH MACHINE LEARNING BASELINE

8.1. Biểu diễn văn bản bằng TF-IDF

Sử dụng TF-IDF để chuyển văn bản thành vector đặc trưng.

Cấu hình dự kiến:

- n-gram: 1-2.

- max_features: khoảng 10.000-20.000 tùy quy mô dữ liệu.
- Có thể điều chỉnh tham số thông qua validation.

Pipeline:

Text → TF-IDF → Feature Matrix.

---

9. CÁC MÔ HÌNH BASELINE

Để tập trung vào nội dung chính của môn Học máy, nhóm sử dụng hai mô hình chính.

9.1. Logistic Regression

Pipeline:

TF-IDF → Logistic Regression → Sentiment.

Logistic Regression được sử dụng làm mô hình phân loại tuyến tính cơ bản.

9.2. LinearSVC

Pipeline:

TF-IDF → LinearSVC → Sentiment.

LinearSVC được lựa chọn vì phù hợp với dữ liệu văn bản có số chiều đặc trưng lớn.

Không bắt buộc triển khai quá nhiều mô hình phụ như Random Forest hoặc Naive Bayes nếu không tạo thêm giá trị cho câu hỏi nghiên cứu.

---

10. THỰC NGHIỆM IN-DOMAIN

Đánh giá khả năng của mô hình khi dữ liệu huấn luyện và kiểm thử thuộc cùng một miền.

Thí nghiệm A

Train trên Domain A → Test trên Domain A.

Thí nghiệm B

Train trên Domain B → Test trên Domain B.

Mục đích:

- Xác định hiệu năng cơ sở của mô hình.
- So sánh sự khác biệt giữa hai miền.
- Làm cơ sở cho việc đánh giá Cross-domain.

---

11. THỰC NGHIỆM CROSS-DOMAIN

Đây là nội dung trọng tâm của đề tài.

Thí nghiệm C

Train trên Domain A → Test trên Domain B.

Thí nghiệm D

Train trên Domain B → Test trên Domain A.

Ma trận thực nghiệm:

Kịch bản	Training	Testing
A → A	Domain A	Domain A
B → B	Domain B	Domain B
A → B	Domain A	Domain B

B → A Domain B Domain A

---

12. ĐÁNH GIÁ ẢNH HƯỞNG CỦA DOMAIN SHIFT

Sử dụng Macro-F1 làm chỉ số chính.

Có thể tính mức suy giảm:

Performance Drop = Macro-F1(In-domain) - Macro-F1(Cross-domain)

Ví dụ:

Nếu:

Macro-F1(A → A) = 0.85

Macro-F1(A → B) = 0.65

thì:

Performance Drop = 0.20.

Chỉ số này được sử dụng để mô tả mức độ ảnh hưởng của việc thay đổi miền dữ liệu.

---

13. MÔ HÌNH NÂNG CAO - PHOBERT

Sau khi hoàn thành Baseline Machine Learning, nhóm triển khai PhoBERT.

13.1. Mục tiêu

So sánh khả năng biểu diễn ngữ nghĩa của Transformer với biểu diễn TF-IDF.

13.2. Quy trình

Review text

↓

PhoBERT Tokenizer

↓

PhoBERT

↓

Classification Head

↓

Negative / Neutral / Positive

13.3. Thực nghiệm

PhoBERT được đánh giá trong:

- In-domain.
- Cross-domain.

Kết quả được so sánh trực tiếp với Logistic Regression và LinearSVC.

---

14. FOCAL LOSS

Focal Loss không được mặc định xem là phương pháp bắt buộc.

Đầu tiên nhóm kiểm tra phân bố sentiment.

Nếu dữ liệu có sự mất cân bằng đáng kể, tiến hành so sánh:

- PhoBERT + Cross Entropy.
- PhoBERT + Focal Loss.

Mục tiêu là kiểm tra liệu Focal Loss có cải thiện khả năng nhận diện các lớp ít xuất hiện hay không.

Nếu dữ liệu tương đối cân bằng hoặc tài nguyên hạn chế, Focal Loss có thể được xem là thí nghiệm bổ sung.

---

15. CHỈ SỐ ĐÁNH GIÁ

15.1. Chỉ số chính

Macro-F1 Score

Đây là chỉ số chính do bài toán có khả năng xuất hiện sự mất cân bằng giữa các lớp.

15.2. Các chỉ số bổ sung

- Accuracy.
- Precision.
- Recall.
- F1-score của từng lớp.

15.3. Confusion Matrix

Xây dựng Confusion Matrix cho các mô hình chính để quan sát:

- Negative bị dự đoán thành Neutral/Positive.
- Neutral bị dự đoán thành Negative/Positive.
- Positive bị dự đoán thành Neutral/Negative.

---

16. ERROR ANALYSIS

Sau khi hoàn thành thực nghiệm, nhóm lựa chọn khoảng 10-20 trường hợp dự đoán sai tiêu biểu.

Các nhóm lỗi dự kiến:

16.1. Domain-specific vocabulary

Từ vựng đặc trưng của một miền không xuất hiện hoặc ít xuất hiện trong miền còn lại.

16.2. Sarcasm

Các câu mang tính mỉa mai/châm biếm.

16.3. Phủ định

Các câu có cấu trúc phủ định đơn hoặc phủ định phức tạp.

16.4. Mixed Sentiment

Một review đồng thời chứa cả thông tin tích cực và tiêu cực.

16.5. Rating và nội dung không nhất quán

Nội dung review và rating có thể thể hiện hai tín hiệu khác nhau.

16.6. Teencode và viết tắt

Các cách viết không chuẩn gây khó khăn cho mô hình.

16.7. Review quá ngắn

Review chỉ gồm một vài từ hoặc một câu ngắn.

16.8. Domain Shift

Từ vựng hoặc cách diễn đạt có ý nghĩa khác nhau giữa hai miền.

Mỗi trường hợp được trình bày theo cấu trúc:

Review	Nhãn thật	Dự đoán	Mô hình	Phân tích nguyên nhân

---

17. BẢNG THỰC NGHIỆM DỰ KIẾN

Mô hình	A→A	B→B	A→B	B→A
TF-IDF + Logistic Regression	✓	✓	✓	✓
TF-IDF + LinearSVC	✓	✓	✓	✓
PhoBERT	✓	✓	✓	✓
PhoBERT + Focal Loss*	✓	✓	✓	✓

(*) Chạy khi dữ liệu có mất cân bằng đáng kể hoặc nhóm có đủ thời gian và tài nguyên tính toán.

---

18. PHÂN CHIA NHIỆM VỤ

THÀNH VIÊN 1 - DATA & EDA

Nhiệm vụ

- Khảo sát và thu thập hai dataset.
- Kiểm tra nguồn và license.
- Làm sạch dữ liệu.
- Chuẩn hóa label.
- Loại duplicate.
- Sampling nếu dataset quá lớn.
- Xây dựng preprocessing pipeline.
- Thực hiện EDA.
- Vẽ biểu đồ phân bố dữ liệu.
- Phân tích vocabulary giữa hai domain.

Deliverables

- Dataset đã xử lý.
- Script preprocessing.
- Notebook EDA.
- Các biểu đồ.

- Bảng thống kê dataset.
- Nội dung phần Dữ liệu và EDA trong báo cáo.

THÀNH VIÊN 2 - MACHINE LEARNING BASELINE

Nhiệm vụ

- Xây dựng TF-IDF.
- Huấn luyện Logistic Regression.
- Huấn luyện LinearSVC.
- Chạy In-domain experiments.
- Chạy Cross-domain experiments.
- Tính Metrics.
- Tạo Confusion Matrix.
- Tổng hợp bảng kết quả.

Deliverables

- Code Baseline.
- Model checkpoint.
- File kết quả thực nghiệm.
- Confusion Matrix.
- Bảng so sánh kết quả.
- Nội dung phần Machine Learning trong báo cáo.

THÀNH VIÊN 3 - PHOBERT & ANALYSIS

Nhiệm vụ

- Xây dựng PhoBERT pipeline.
- Fine-tuning PhoBERT.
- Thực hiện In-domain và Cross-domain.

- Triển khai Focal Loss nếu cần.
- So sánh PhoBERT với Baseline.
- Thu thập các mẫu dự đoán sai.
- Thực hiện Error Analysis.
- Tổng hợp nhận xét.

Deliverables

- Code PhoBERT.
- Checkpoint/model.
- Kết quả thực nghiệm.
- Bảng Error Analysis.
- Nội dung phần PhoBERT và Error Analysis.

---

19. TIẾN ĐỘ THỰC HIỆN

TUẦN 1 - KHẢO SÁT DỮ LIỆU VÀ TIỀN XỬ LÝ

Công việc chung

- Chốt đề tài.
- Chốt hai dataset.
- Kiểm tra license.
- Tạo Git repository.
- Thiết lập môi trường Python.

Thành viên 1

- Download dataset.
- Cleaning.
- Label mapping.
- EDA bước đầu.

Thành viên 2

- Xây dựng TF-IDF pipeline.
- Chuẩn bị Baseline.

Thành viên 3

- Chuẩn bị môi trường PyTorch/HuggingFace.
- Kiểm tra PhoBERT.

Kết quả cuối tuần

- Có hai dataset.
- Có preprocessing pipeline.
- Có thống kê dữ liệu ban đầu.
- TF-IDF pipeline chạy được.
- PhoBERT pipeline có thể chạy thử.

TUẦN 2 - MACHINE LEARNING BASELINE

Thành viên 1

- Hoàn thiện EDA.
- Phân tích vocabulary.
- Hoàn thiện biểu đồ.

Thành viên 2

- Logistic Regression.
- LinearSVC.
- In-domain experiments.
- Cross-domain experiments.

Thành viên 3

- Chuẩn bị DataLoader.
- Tokenization.

- Chạy thử PhoBERT.

Kết quả cuối tuần

- Hoàn thành Baseline.
- Có kết quả In-domain.
- Có kết quả Cross-domain ban đầu.
- PhoBERT chạy được trên một tập dữ liệu thử nghiệm.

TUẦN 3 - PHOBERT VÀ SO SÁNH

Thành viên 1

- Hoàn thiện bảng thống kê dữ liệu.
- Hỗ trợ trực quan hóa kết quả.

Thành viên 2

- Kiểm tra lại Baseline.
- Chuẩn hóa toàn bộ Metrics.
- Tổng hợp kết quả.

Thành viên 3

- Fine-tune PhoBERT.
- Chạy In-domain.
- Chạy Cross-domain.
- Chạy Focal Loss nếu cần.

Kết quả cuối tuần

- Có đầy đủ kết quả chính.
- Có bảng so sánh mô hình.
- Có Confusion Matrix.
- Bắt đầu Error Analysis.

TUẦN 4 - PHÂN TÍCH VÀ HOÀN THIỆN BÁO CÁO

Công việc chung

- Error Analysis.
- Phân tích Domain Shift.
- So sánh mô hình.
- Hoàn thiện biểu đồ.
- Viết báo cáo.
- Kiểm tra code.
- Kiểm tra khả năng chạy lại kết quả.

Kết quả cuối tuần

- Báo cáo hoàn chỉnh.
- Source code hoàn chỉnh.
- Dataset processing pipeline.
- Bảng kết quả.
- Biểu đồ.
- Confusion Matrix.
- Error Analysis.
- README hướng dẫn chạy.

---

20. CẤU TRÚC SOURCE CODE DỰ KIẾN

- sentiment-cross-domain/
- │
- ├── data/
- │ ├── raw/
- │ └── processed/
- │
- ├── notebooks/

- │   ├── 01_eda.ipynb
- │   ├── 02_baseline.ipynb
- │   └── 03_phobert.ipynb
- │
- ├── src/
- │   ├── preprocessing.py
- │   ├── dataset.py
- │   ├── baseline.py
- │   ├── phobert.py
- │   ├── focal_loss.py
- │   └── evaluation.py
- │
- ├── results/
- │   ├── metrics/
- │   ├── figures/
- │   └── confusion_matrix/
- │
- ├── models/
- │
- ├── requirements.txt
- ├── README.md

└── report/

---

21. CẤU TRÚC BÁO CÁO

CHƯƠNG 1. GIỚI THIỆU

1.1. Đặt vấn đề

1.2. Lý do chọn đề tài

1.3. Mục tiêu

1.4. Câu hỏi nghiên cứu

1.5. Phạm vi đề tài

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Sentiment Analysis

2.2. Xử lý văn bản tiếng Việt

2.3. TF-IDF

2.4. Logistic Regression

2.5. LinearSVC

2.6. Transformer

2.7. PhoBERT

2.8. Focal Loss

2.9. Cross-domain Learning và Domain Shift

CHƯƠNG 3. DỮ LIỆU VÀ PHƯƠNG PHÁP

3.1. Mô tả Dataset A

3.2. Mô tả Dataset B

3.3. Chuẩn hóa nhãn

3.4. Tiền xử lý

3.5. EDA

3.6. TF-IDF

3.7. Baseline Models

3.8. PhoBERT

3.9. Thiết kế thực nghiệm

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1. Kết quả In-domain

4.2. Kết quả Cross-domain

4.3. So sánh Logistic Regression và LinearSVC

4.4. So sánh Baseline và PhoBERT

4.5. Đánh giá Focal Loss

4.6. Confusion Matrix

4.7. Phân tích Performance Drop

CHƯƠNG 5. ERROR ANALYSIS

5.1. Phân tích lỗi về vocabulary

5.2. Phân tích lỗi phủ định

5.3. Phân tích lỗi sarcasm

5.4. Phân tích mixed sentiment

5.5. Phân tích Domain Shift

5.6. Tổng hợp các trường hợp dự đoán sai

CHƯƠNG 6. KẾT LUẬN

6.1. Kết quả đạt được

6.2. Trả lời các câu hỏi nghiên cứu

6.3. Hạn chế

6.4. Hướng phát triển

---

22. SẢN PHẨM CUỐI CÙNG

Nhóm cần hoàn thành:

1. Báo cáo

- Báo cáo PDF.
- Đầy đủ các chương.
- Có bảng kết quả.
- Có biểu đồ.
- Có Confusion Matrix.
- Có Error Analysis.
- Có tài liệu tham khảo.

2. Source Code

- Preprocessing.
- EDA.

- TF-IDF.
- Logistic Regression.
- LinearSVC.
- PhoBERT.
- Evaluation.

3. Kết quả thực nghiệm

- In-domain.
- Cross-domain.
- So sánh các mô hình.
- Macro-F1.
- Precision.
- Recall.
- Accuracy.
- Confusion Matrix.

4. README

README cần hướng dẫn:

1. Cài đặt môi trường.
2. Chuẩn bị dataset.
3. Chạy preprocessing.
4. Chạy baseline.
5. Chạy PhoBERT.
6. Đánh giá kết quả.

---

23. NGUYÊN TẮC THỰC HIỆN

1. Không đánh giá mô hình chỉ bằng Accuracy.
2. Macro-F1 là chỉ số chính.
3. Phải giữ cùng cách chia dữ liệu khi so sánh các mô hình.
4. Phải cố định random seed khi có thể.
5. Không sử dụng test set để điều chỉnh hyperparameter.

6. Phải tách validation và test.
7. Không để dữ liệu trùng lặp giữa train và test.
8. Dataset phải có nguồn rõ ràng.
9. Phải ghi rõ phương pháp sampling nếu dataset quá lớn.
10. Kết quả phải có thể tái hiện lại từ source code.
11. Cross-domain phải được đánh giá riêng với In-domain.
12. Error Analysis phải dựa trên các trường hợp dự đoán sai thực tế.
13. Không mặc định mô hình phức tạp hơn sẽ tốt hơn; kết luận phải dựa trên kết quả thực nghiệm.
14. Các hạn chế của dataset và mô hình phải được trình bày rõ trong báo cáo.

---

24. KẾT QUẢ KỲ VỌNG

Sau khi hoàn thành, nhóm có thể trả lời được:

- Mô hình Machine Learning nào hoạt động tốt nhất trên từng miền?
- PhoBERT có cải thiện so với TF-IDF hay không?
- Domain Shift ảnh hưởng đến Macro-F1 như thế nào?
- Chuyển từ E-commerce sang Hotel/Restaurant có khó hơn chiều ngược lại hay không?
- Focal Loss có thực sự cải thiện kết quả khi dữ liệu mất cân bằng hay không?
- Những loại câu nào khiến mô hình dự đoán sai nhiều nhất?

Thông qua đó, đề tài không chỉ xây dựng một hệ thống phân loại sentiment mà còn phân tích được **khả năng tổng quát hóa của mô hình học máy giữa các miền dữ liệu khác nhau**.

---

25. PHẠM VI VÀ GIỚI HẠN

Do đây là bài tập lớn môn Học máy, nhóm tập trung vào:

- Phân loại sentiment 3 lớp.
- Hai miền dữ liệu.
- Machine Learning truyền thống.
- Một mô hình Transformer nâng cao.

- Cross-domain evaluation.
- Error Analysis.

Nhóm không tập trung vào:

- Xây dựng hệ thống thương mại hoàn chỉnh.
- Triển khai production.
- Thu thập dữ liệu theo thời gian thực.
- Xây dựng mô hình ngôn ngữ từ đầu.
- Huấn luyện PhoBERT từ đầu.
- Các bài toán Aspect-Based Sentiment Analysis chuyên sâu nếu không cần thiết cho mục tiêu chính.

Việc giới hạn phạm vi nhằm đảm bảo nhóm hoàn thành đầy đủ pipeline và có kết quả thực nghiệm đáng tin cậy trong thời gian của bài tập lớn.

---

26. KẾT LUẬN KẾ HOẠCH

Đề tài được xây dựng theo pipeline:

Dataset → Preprocessing → EDA → TF-IDF → Machine Learning Baseline → In-domain Evaluation → Cross-domain Evaluation → PhoBERT → Focal Loss (nếu cần) → Error Analysis → So sánh và kết luận.

Trọng tâm của đề tài là đánh giá khả năng tổng quát hóa của mô hình học máy trong điều kiện dữ liệu thuộc các miền khác nhau, đồng thời so sánh giữa phương pháp Machine Learning truyền thống và mô hình Transformer tiếng Việt.